



Dự đoán Đỉnh tải trong Hệ thống Serverless

Giảm thiểu Khởi động lạnh bằng Machine Learning (LSTM)

July 5, 2026

Vấn đề: Khởi động lạnh (Cold Start)

Đặc điểm Serverless (Knative):

- Tự động thu hẹp về 0 Pods (Scale-to-Zero)

Vấn đề: Khởi động lạnh (Cold Start)

Đặc điểm Serverless (Knative):

- Tự động thu hẹp về 0 Pods (Scale-to-Zero)
- Tiết kiệm tối đa chi phí.

Vấn đề: Khởi động lạnh (Cold Start)

Đặc điểm Serverless (Knative):

- Tự động thu hẹp về 0 Pods (Scale-to-Zero)
- Tiết kiệm tối đa chi phí.

Thách thức:

- Khi request đầu tiên tới, hệ thống mất từ 3 → 5 giây để khởi động Container mới.


Vấn đề: Khởi động lạnh (Cold Start)

Đặc điểm Serverless (Knative):

- Tự động thu hẹp về 0 Pods (Scale-to-Zero)
- Tiết kiệm tối đa chi phí.

Thách thức:

- Khi request đầu tiên tới, hệ thống mất từ 3 → 5 giây để khởi động Container mới.
- Gây trải nghiệm cực tồi tệ cho người dùng (Latency tăng vọt).



Knative Pod Autoscaler (KPA) hoạt động theo cơ chế Phản ứng (Reactive):

1. Xảy ra đột biến lưu lượng (Spike).

Knative Pod Autoscaler (KPA) hoạt động theo cơ chế Phản ứng (Reactive):

1. Xảy ra đột biến lưu lượng (Spike).
2. KPA phát hiện Concurrency tăng cao.

Knative Pod Autoscaler (KPA) hoạt động theo cơ chế Phản ứng (Reactive):

1. Xảy ra đột biến lưu lượng (Spike).
2. KPA phát hiện Concurrency tăng cao.
3. **Quá muộn!** Request đã bị nghẽn ở Activator.

Knative Pod Autoscaler (KPA) hoạt động theo cơ chế Phản ứng (Reactive):

1. Xảy ra đột biến lưu lượng (Spike).
2. KPA phát hiện Concurrency tăng cao.
3. **Quá muộn!** Request đã bị nghẽn ở Activator.
4. Hệ thống hốt hải Scale-up, gây hiệu ứng domino làm lag toàn cụm.

Knative Pod Autoscaler (KPA) hoạt động theo cơ chế Phản ứng (Reactive):

1. Xảy ra đột biến lưu lượng (Spike).
2. KPA phát hiện Concurrency tăng cao.
3. **Quá muộn!** Request đã bị nghẽn ở Activator.
4. Hệ thống hút hải Scale-up, gây hiệu ứng domino làm lag toàn cụm.

Giải pháp cần có

Thay vì **Chờ đợi (Reactive)**, hệ thống phải **Đón đầu (Predictive)**!

Sử dụng **Học máy (Machine Learning)** để phân tích dữ liệu lịch sử và dự báo tải!

- **Mô hình:** Mạng nơ-ron LSTM (Long Short-Term Memory).


Sử dụng **Học máy (Machine Learning)** để phân tích dữ liệu lịch sử và dự báo tải!

- **Mô hình:** Mạng nơ-ron LSTM (Long Short-Term Memory).
- **Ưu điểm:** Cực kỳ giỏi trong việc nhớ các chuỗi thời gian dài và phát hiện chu kỳ (pattern) của Traffic.


Sử dụng **Học máy (Machine Learning)** để phân tích dữ liệu lịch sử và dự báo tải!

- **Mô hình:** Mạng nơ-ron LSTM (Long Short-Term Memory).
- **Ưu điểm:** Cực kỳ giỏi trong việc nhớ các chuỗi thời gian dài và phát hiện chu kỳ (pattern) của Traffic.
- **Chiến lược:** "Pre-warming" - Mở rộng số lượng Pod *trước* khi đợt sóng traffic thực sự ập đến 5-10 giây.

Cốt lõi AI: Tế bào LSTM




Cốt lõi AI: Tế bào LSTM



3 Cổng chính: Quên (Forget) - Đầu vào (Input) - Đầu ra (Output) giúp LSTM lọc nhiễu cực tốt.

Kiến trúc Tổng thể của Hệ thống



Thuật toán Làm mịn (Chống Thrashing)

Bảo vệ Control Plane của Kubernetes khỏi các đợt "giật lag" khi model AI dự đoán biến động mạnh.


Quy tắc ràng buộc:

- **Min-Max Bounds:** Không bé hơn 1, không lớn hơn 10.
- **Cửa sổ vận tốc:**
 - Tăng nhanh: Tối đa +2 Pods / chu kỳ.
 - Giảm chậm: Tối đa -1 Pod / chu kỳ.

Nguyên lý

"Mở rộng nhanh để chống nghẽn, Thu hẹp chậm để chống dư chấn (aftershocks)".

Kịch bản Đỉnh tải 3 Pha (3-Phase Spike)



Kết quả Thực nghiệm so sánh

Chỉ số Đánh giá	Knative (Reactive)	Predictive (LSTM)
Khởi động lạnh (Cold Starts)	100% (Toàn bộ 9 Pods)	0% (Triệt tiêu)

Kết quả Thực nghiệm so sánh

Chỉ số Đánh giá	Knative (Reactive)	Predictive (LSTM)
Khởi động lạnh (Cold Starts)	100% (Toàn bộ 9 Pods)	0% (Triệt tiêu)
Độ trễ trung bình đợt đầu	3500 ms	120 ms

Kết quả Thực nghiệm so sánh

Chỉ số Đánh giá	Knative (Reactive)	Predictive (LSTM)
Khởi động lạnh (Cold Starts)	100% (Toàn bộ 9 Pods)	0% (Triệt tiêu)
Độ trễ trung bình đợt đầu	3500 ms	120 ms
Hiệu quả tài nguyên	100%	92.5% (Đánh đổi)

Kết quả Thử nghiệm so sánh

Chỉ số Đánh giá	Knative (Reactive)	Predictive (LSTM)
Khởi động lạnh (Cold Starts)	100% (Toàn bộ 9 Pods)	0% (Triệt tiêu)
Độ trễ trung bình đợt đầu	3500 ms	120 ms
Hiệu quả tài nguyên	100%	92.5% (Đánh đổi)
Thời gian đạt đỉnh 10 Pods	~45 giây	20 giây

Kết quả Thử nghiệm so sánh

Chỉ số Đánh giá	Knative (Reactive)	Predictive (LSTM)
Khởi động lạnh (Cold Starts)	100% (Toàn bộ 9 Pods)	0% (Triệt tiêu)
Độ trễ trung bình đợt đầu	3500 ms	120 ms
Hiệu quả tài nguyên	100%	92.5% (Đánh đổi)
Thời gian đạt đỉnh 10 Pods	~45 giây	20 giây

Kết luận nhanh

Đánh đổi 7.5% lượng tài nguyên dư thừa tạm thời để đổi lấy tốc độ phản hồi **nhANH hơn gấp 29 lần!**

Đóng góp của đề tài:

- Khắc phục hoàn toàn bài toán Cold-start trong Serverless (Knative).
- Tích hợp thành công AI (LSTM) vào hệ sinh thái DevOps/Kubernetes.
- Xây dựng Controller giám sát độc lập, an toàn (Smoothing).

Đóng góp của đề tài:

- Khắc phục hoàn toàn bài toán Cold-start trong Serverless (Knative).
- Tích hợp thành công AI (LSTM) vào hệ sinh thái DevOps/Kubernetes.
- Xây dựng Controller giám sát độc lập, an toàn (Smoothing).

Hướng phát triển tương lai:

- Huấn luyện mô hình Transformer thay vì LSTM để tăng tốc.
- Thu thập dữ liệu thực tế (Real-world datasets) từ các sàn E-commerce.